“Machine Learning Language” Workshop
Bildungswerk Südhessen
27.6.2024

Roland Leißa

UNIVERSITÄT MANNHEIM

Outline

1. Über euch und uns
2. Maschinelles Lernen
3. Vorwärts/Rückwärts
4. Workshop

Outline

1. Über euch und uns
2. Maschinelles Lernen
3. Vorwärts/Rückwärts
4. Workshop

Ich bin…

Prof. Dr. Roland Leißa
Lehrstuhl „Programmier-
sprachen und Compilerdesign“

UNIVERSITÄT MANNHEIM

Universität Mannheim (im Schloss!)

Unsere Büros (nicht im Schloss!)

Studienangebot

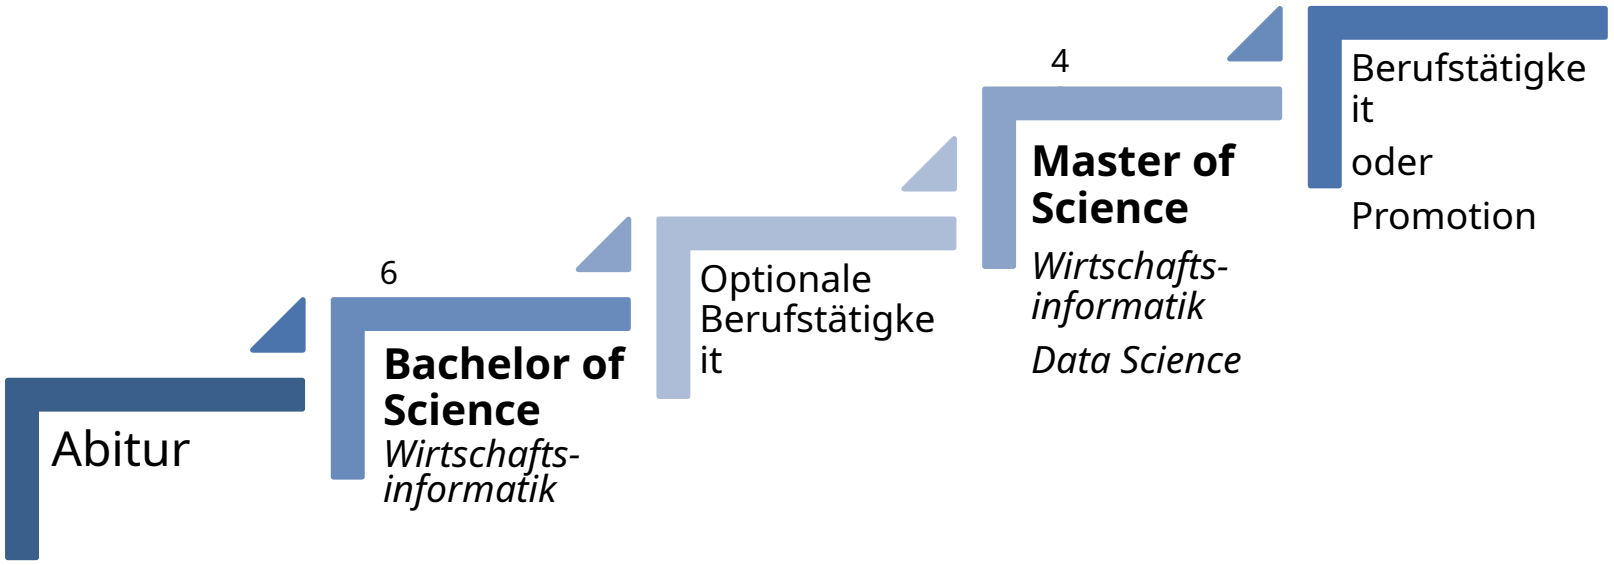

Wirtschaftsinformatik in Mannheim

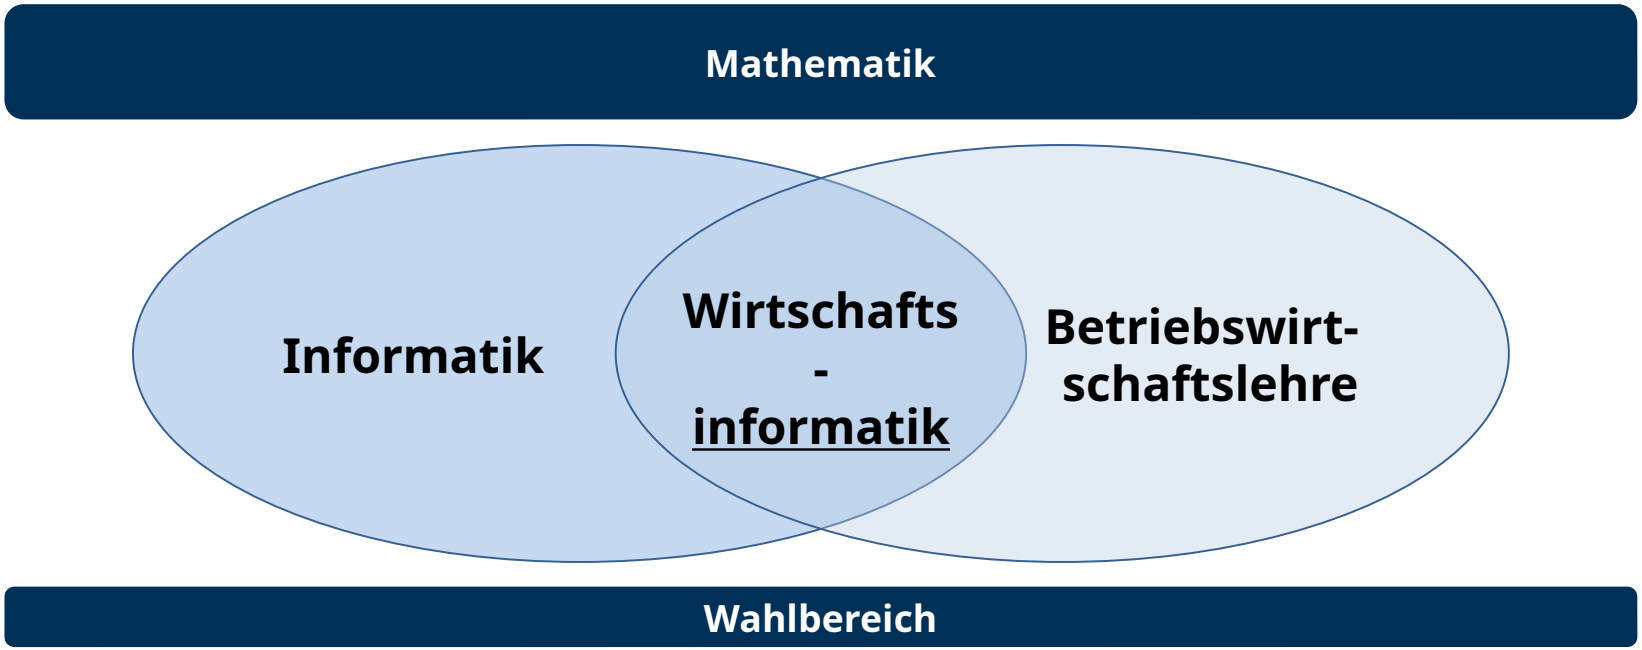

Wifo studiert – und dann?

Startups

Mittel-
stand

Forschun
g

Absolventum Universität Mannheim ✉ Netzwerk

Warum in Mannheim studieren?

Wir bieten:

- guter Ruf (national und international) der Professoren und Professorinnen der Uni Mannheim
- Kontakte in die Wirtschaft
- Vertiefung in BWL, **Informatik** oder Wifo
- Internationale Ausrichtung
- Große Auswahl an Partneruniversitäten
- Studieren im Schloss
- Nähe zu Metropolregion Rhein-Neckar
- Freizeitangebot

Und ihr seid...

Outline

1. Über euch und uns
2. Maschinelles Lernen
3. Vorwärts/Rückwärts
4. Workshop

What is machine learning?

Key question: How can we build computer systems that automatically improve with experience, and what are the fundamental laws that govern all learning processes?

- Easy to write good programs for certain tasks (e.g., shortest path)
- Hard to write good programs for other tasks (e.g., spam detection)
- Machine learning generally comprises
  - A **task** T (e.g., playing Checkers)
  - A **performance metric** P (e.g., percent of games won)
  - Training **experience** E (e.g., playing games)
  - Goal: machine learns to reliably improve performance P at task T, following experience E

In 2016, DeepMind's AlphaGo beat Go master Lee Se-dol

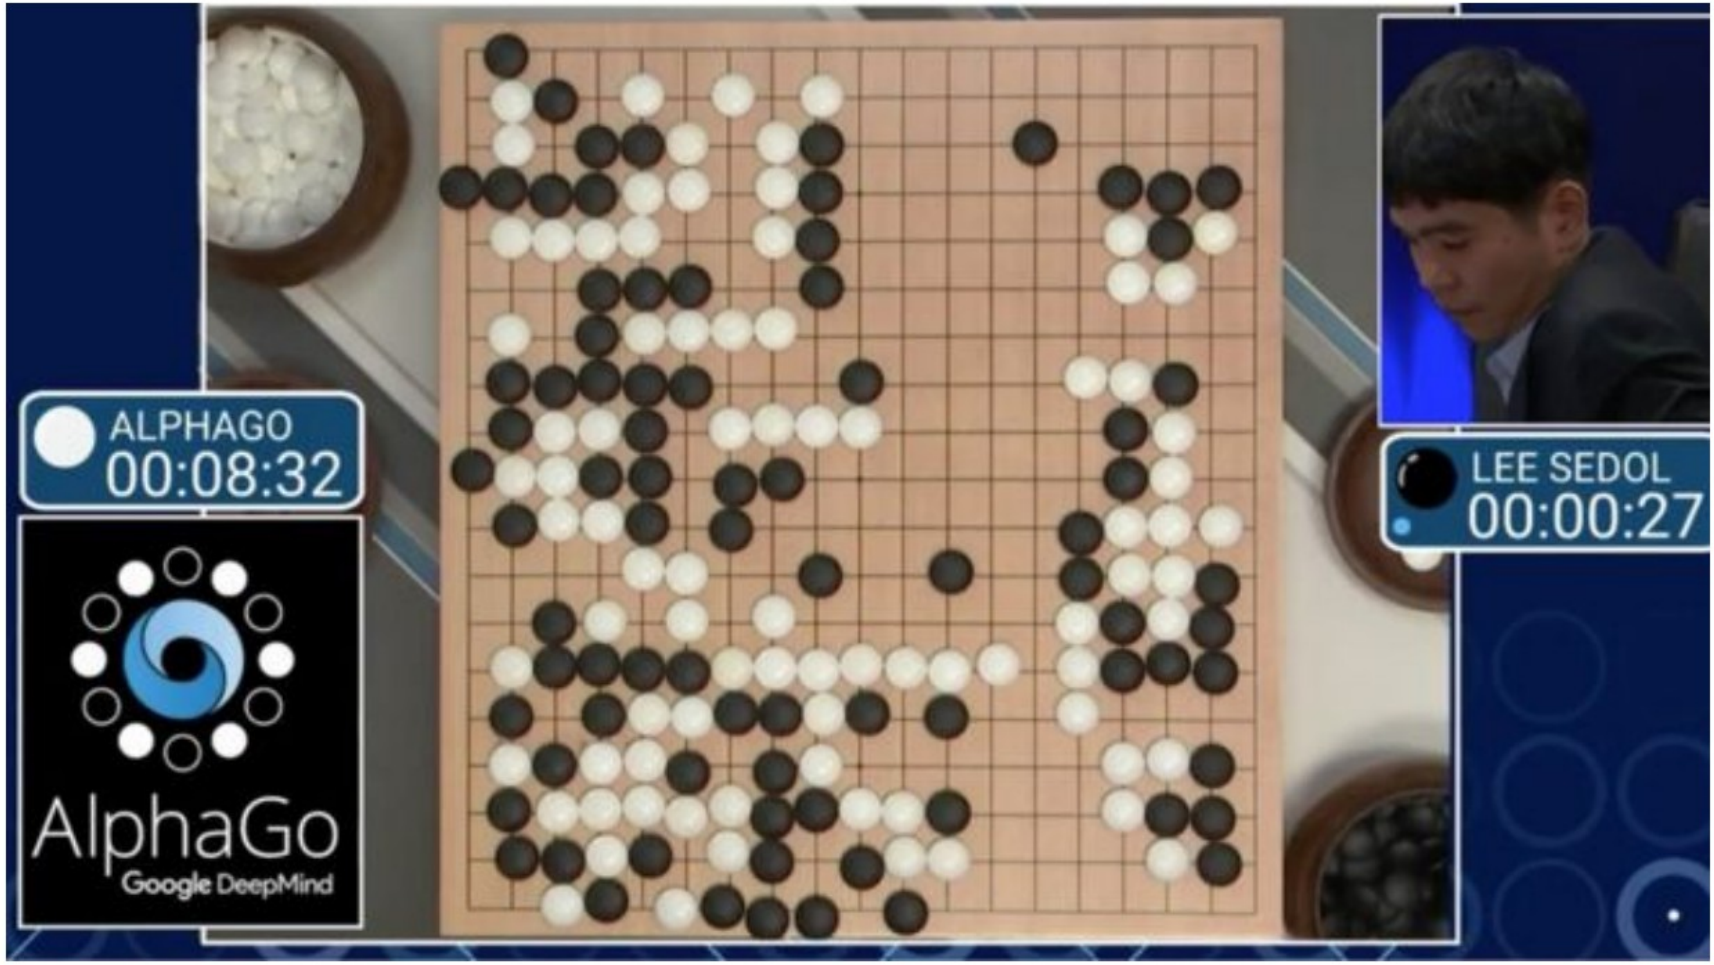

Let's learn!

- Roland distinguishes good and bad triples
- Here is a good triple

2 4 8

- Ask me about triples being good or bad; then tell the rule I use to distinguish (you are allowed to guess only once!)
- Could you write a program that could guess such rules?

Klassifikation

- Diese Aufgabe war eine **Klassifikations**aufgabe
  - Gegeben: **Eingabe** („2 4 8“)
  - Gesucht: **Klasse** („gut“)
  - Endlich viele Klassen
- Andere Beispiele
  - E-Mail -> Spam? („ja“ / „nein“)
  - Go-Feldbelegung -> Nächster Zug?
  - Text -> Nächstes „Wort“?

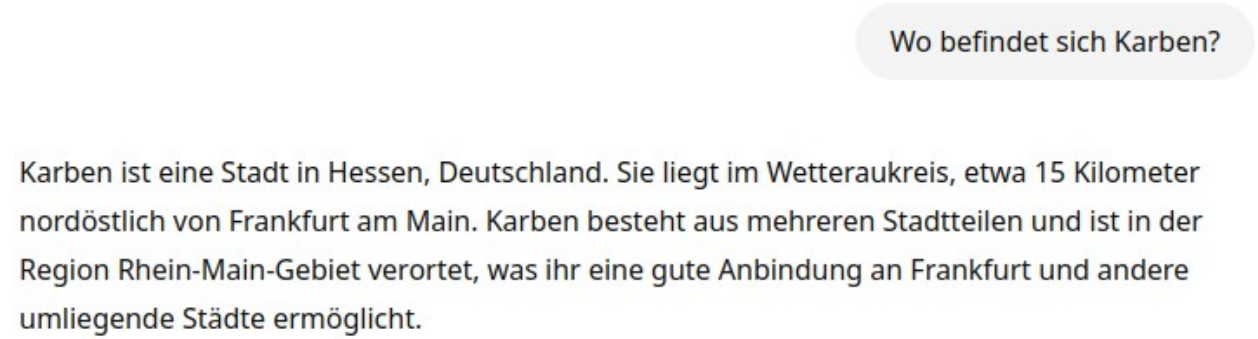

Wie lernt man?

- Was denn überhaupt?
  - Eine Funktion *f*(Eingabe) = Klasse
  - **Machinelles Lernen lernt Funktionen**
- **Beispiel** = Eingabe-Ausgabe Paar
  - „$$$MONEY_RICH_YOU!!!“ -> Spam
- **Überwachtes Lernen**
  - Lernen von (vielen) Beispielen = **Trainingsdaten**
- Und wie?
  - So dass *f* auf den Trainingsdaten gut funktioniert
  - Eigentlich: so dass *f* auf zukünftigen Eingaben gut funktioniert

Beispiel: Logistische Regression

Data

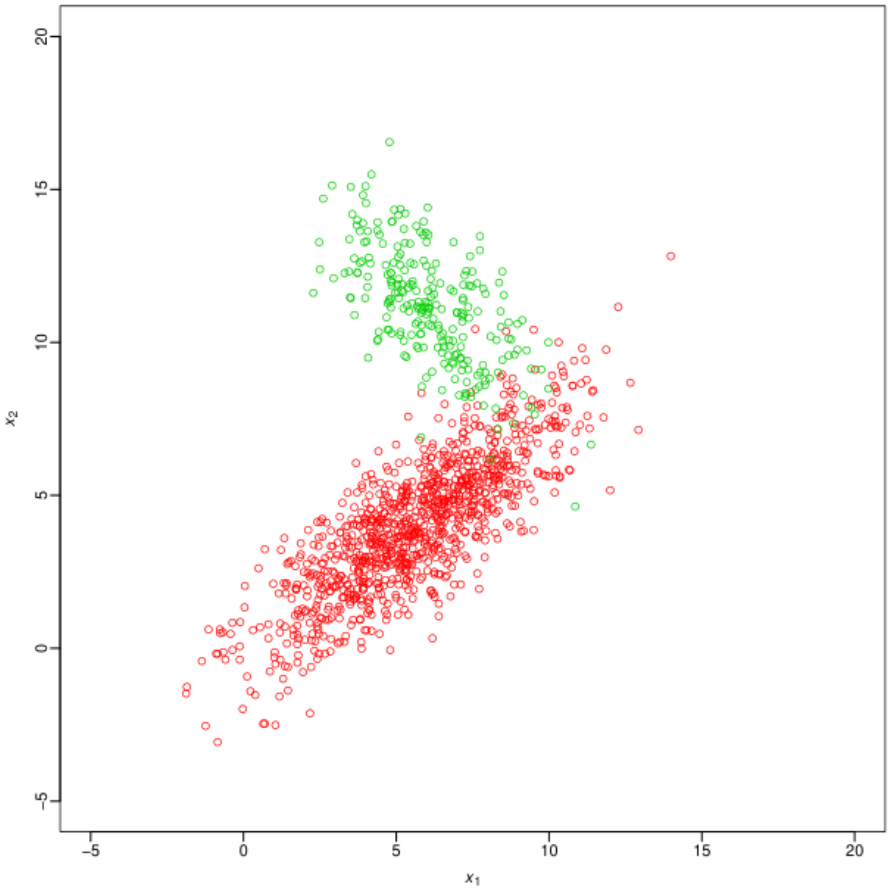

Prediction

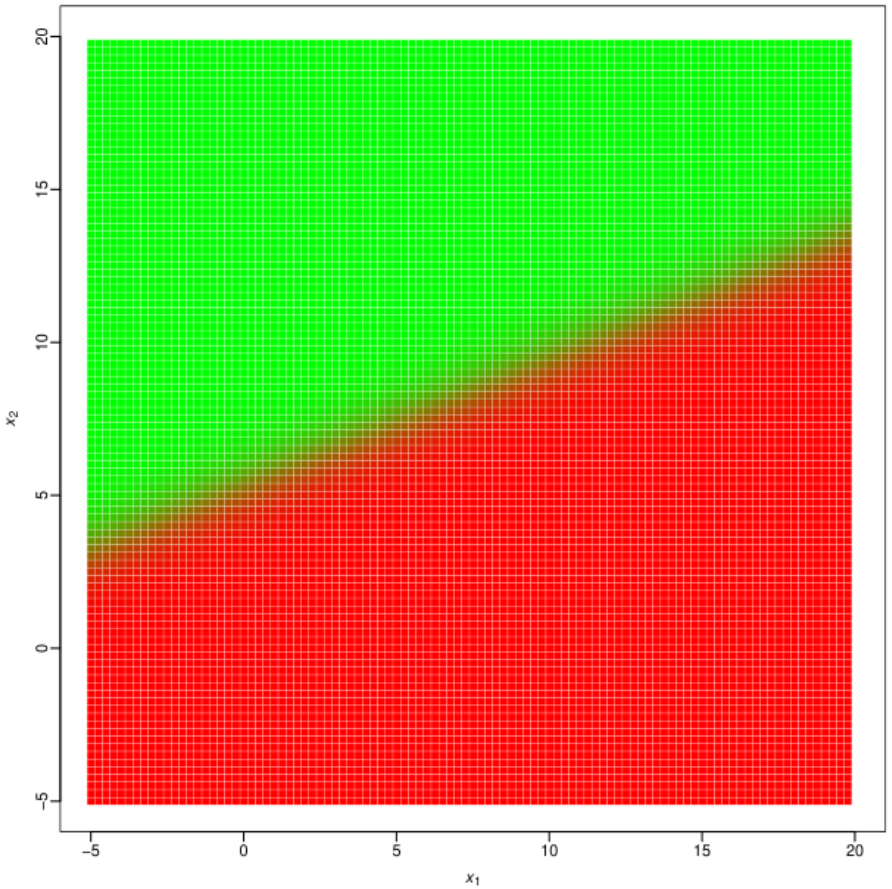

Beispiel: L1VM + Logistische Regression

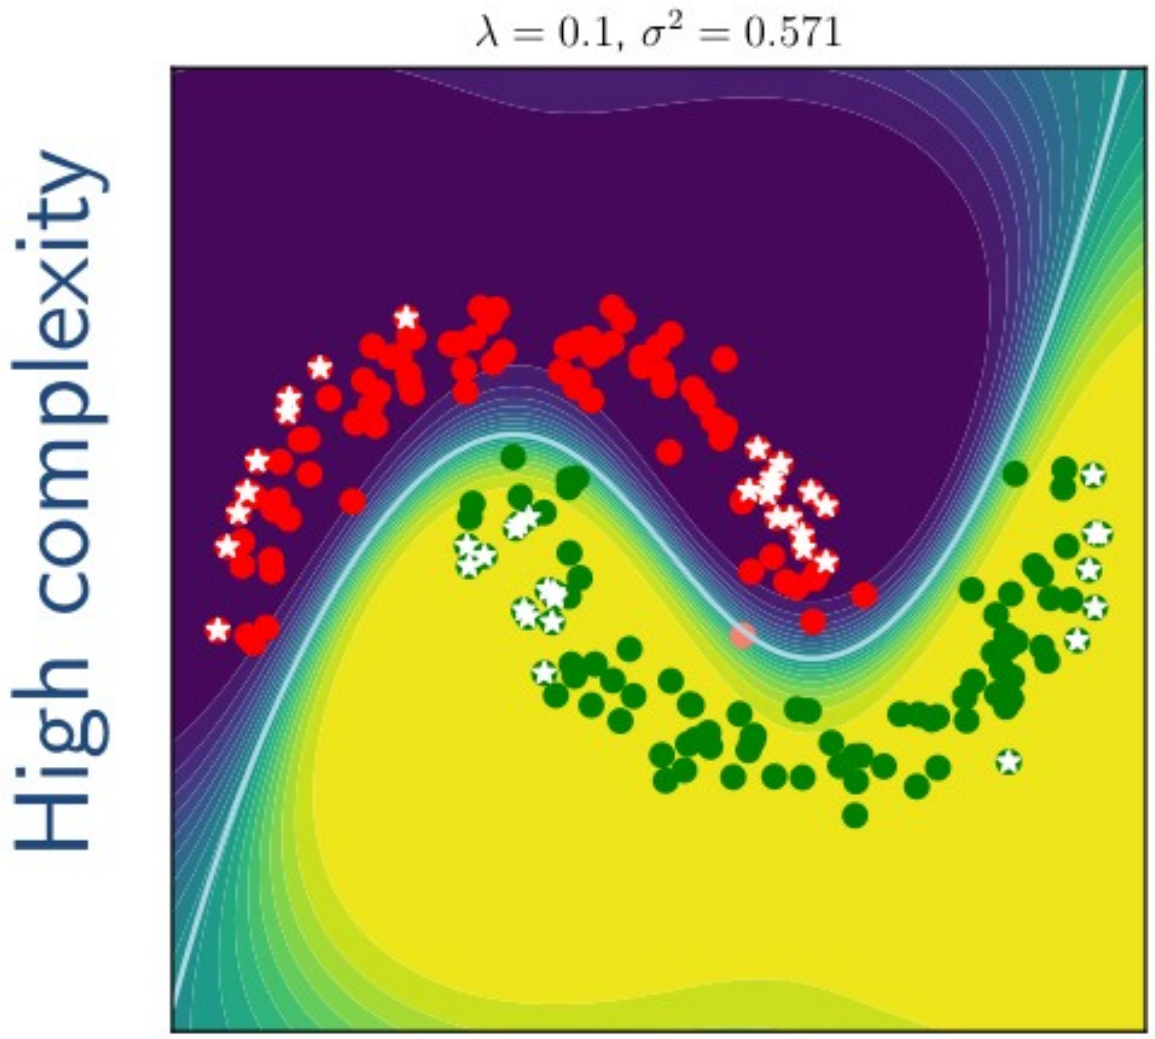

Outline

1. Über euch und uns
2. Maschinelles Lernen
3. Vorwärts/Rückwärts
4. Workshop

Modelle

- Wir haben: Trainingsdaten
- Wir wollen Funktion *f*(Eingabe) -> Klasse
  - So eine Funktion heißt **Modell**
- **Modellklasse** = Menge der in Frage kommenden Funktionen
- Lernen (für heute): Wähle eine der Funktionen aus

Parametrisches Modell

- Eine Modellklasse ist **parametrisch**, wenn jede Funktion der Modellklasse durch eine feste Anzahl **Parameter** beschrieben wird
- Beispiel: f(Einkommen) -> reich / arm?
  - Modellklasse mit Parameter :
    f(Einkommen) = „reich“ wenn Einkommen > sonst „arm“
  - Wir schreiben:
- **Diese Modellklasse ist unendlich groß!**
  - Jede reelle Zahl entspricht einer anderen Funktion
  - Das ist bei den meisten Modellklassen so
  - Anzahl der Parameter: 10, 100, 1000, …., ~2 Billionen
- Lernen = Wähle eine Parameterbelegung aus

Kostenbasiertes Lernen

- Wie wählt man eine Parameterbelegung aus?
- Wir verwenden: **Kostenfunktion** misst Modellgüte
  - Klein -> Modell gut auf Trainingsdaten
  - Groß -> Modell schlecht auf Trainingsdaten
  - Für gegebenes : Für jedes Trainingsbeispiel
    1. Berechne
    2. Bewerte den Unterschied (**loss**) zwischen (richtig) und (momentane Vorhersage)
  - Kostenfunktion z.B. „durchschnittlicher Unterschied“
- **Kostenbasiertes Lernen**
  1. Erstelle eine Kostenfunktion
  2. Minimiere die Kostenfunktion in Bezug auf
  3. So gefundenes = Ausgewählte Parameterbelegung

Beispiel (links blau, rechts rot)

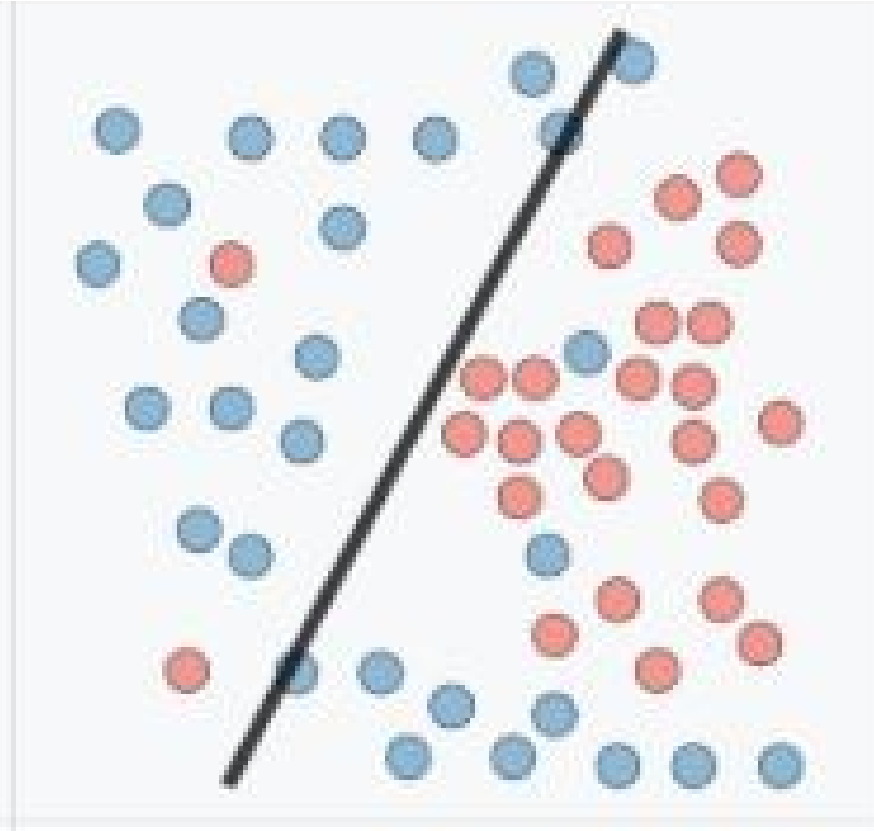

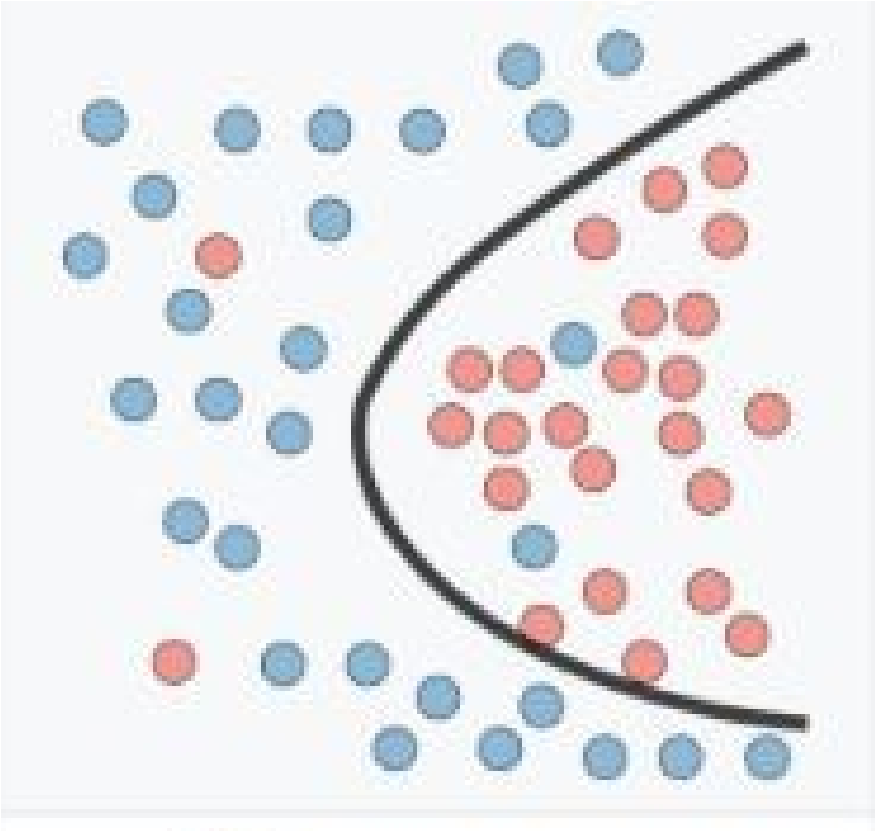

Modell w1
J(w1) = “14 Fehler”
(schlecht)

Modell w2
J(w2) = “4 Fehler”
(gut)

Wie minimiert man die Kostenfunktion?

Ein **iteratives Lernverfahren**:

1. Starte mit einer „beliebigen“ Belegung
2. Bestimme die Kostenfunktion
3. Ändere *w* so dass die Kostenfunktion nach der Änderung etwas kleiner wird
4. Gehe zu Schritt 2

Beispiel () – Wo liegt ?

UNKLAR!

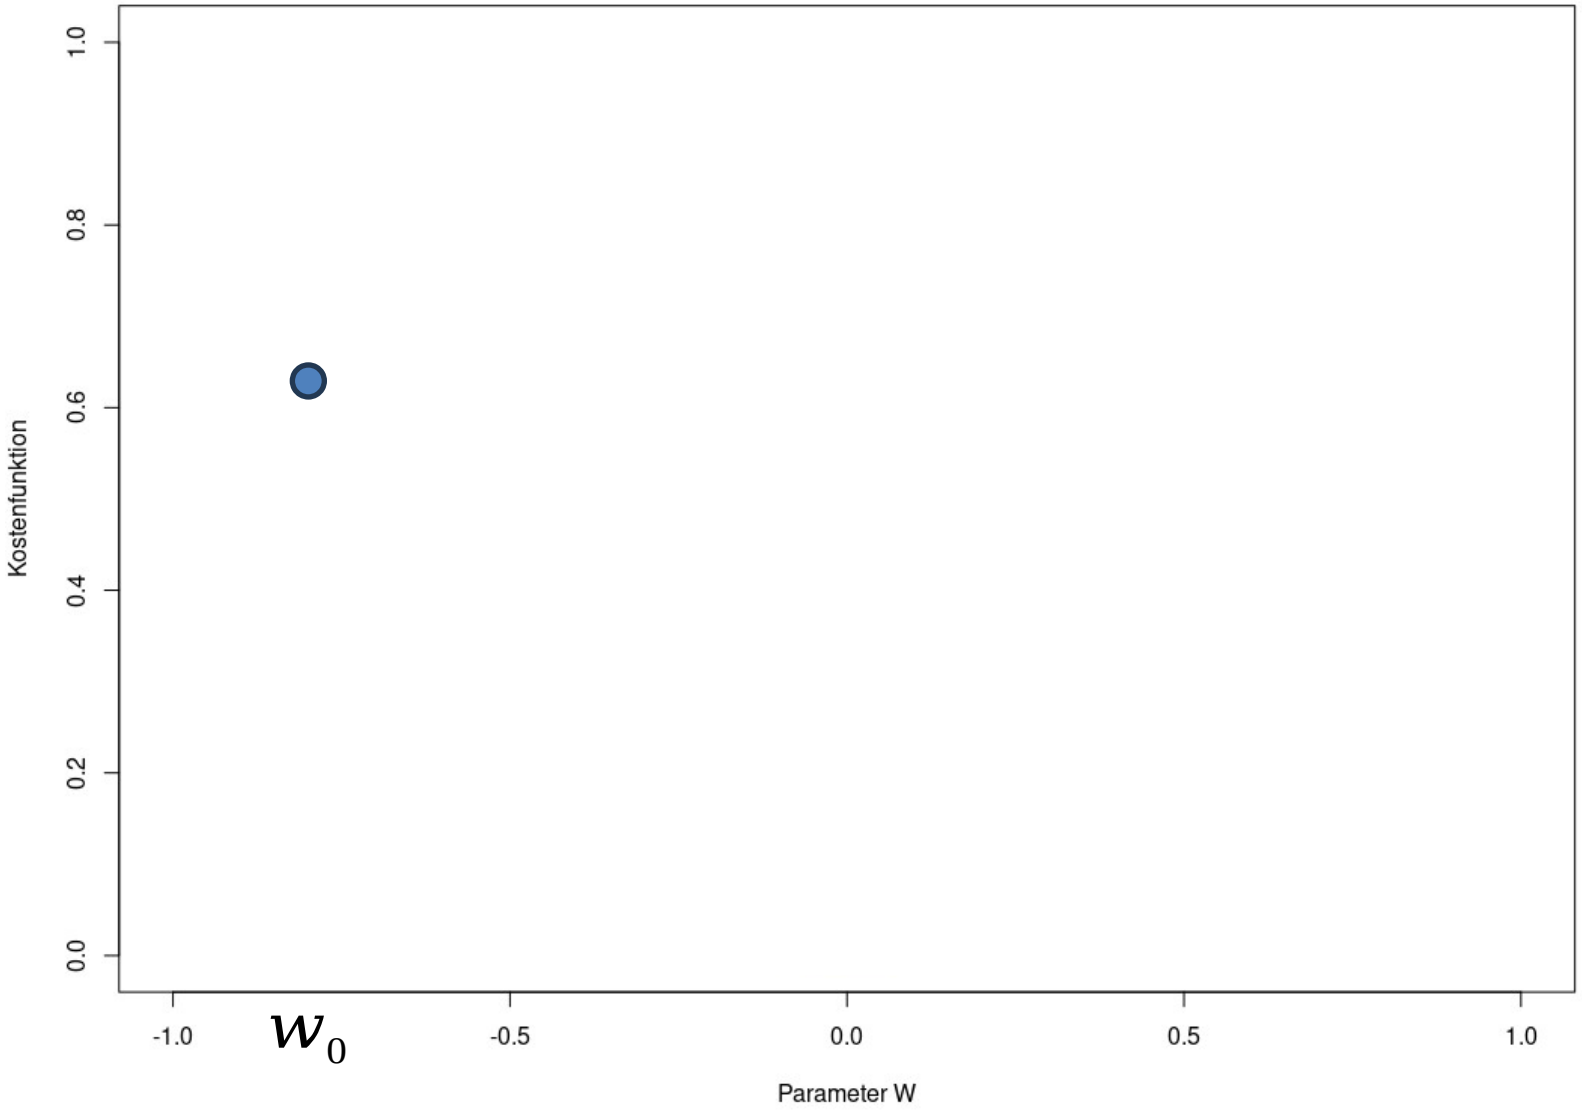

Beispiel () – Wo liegt ?

RECHTS!

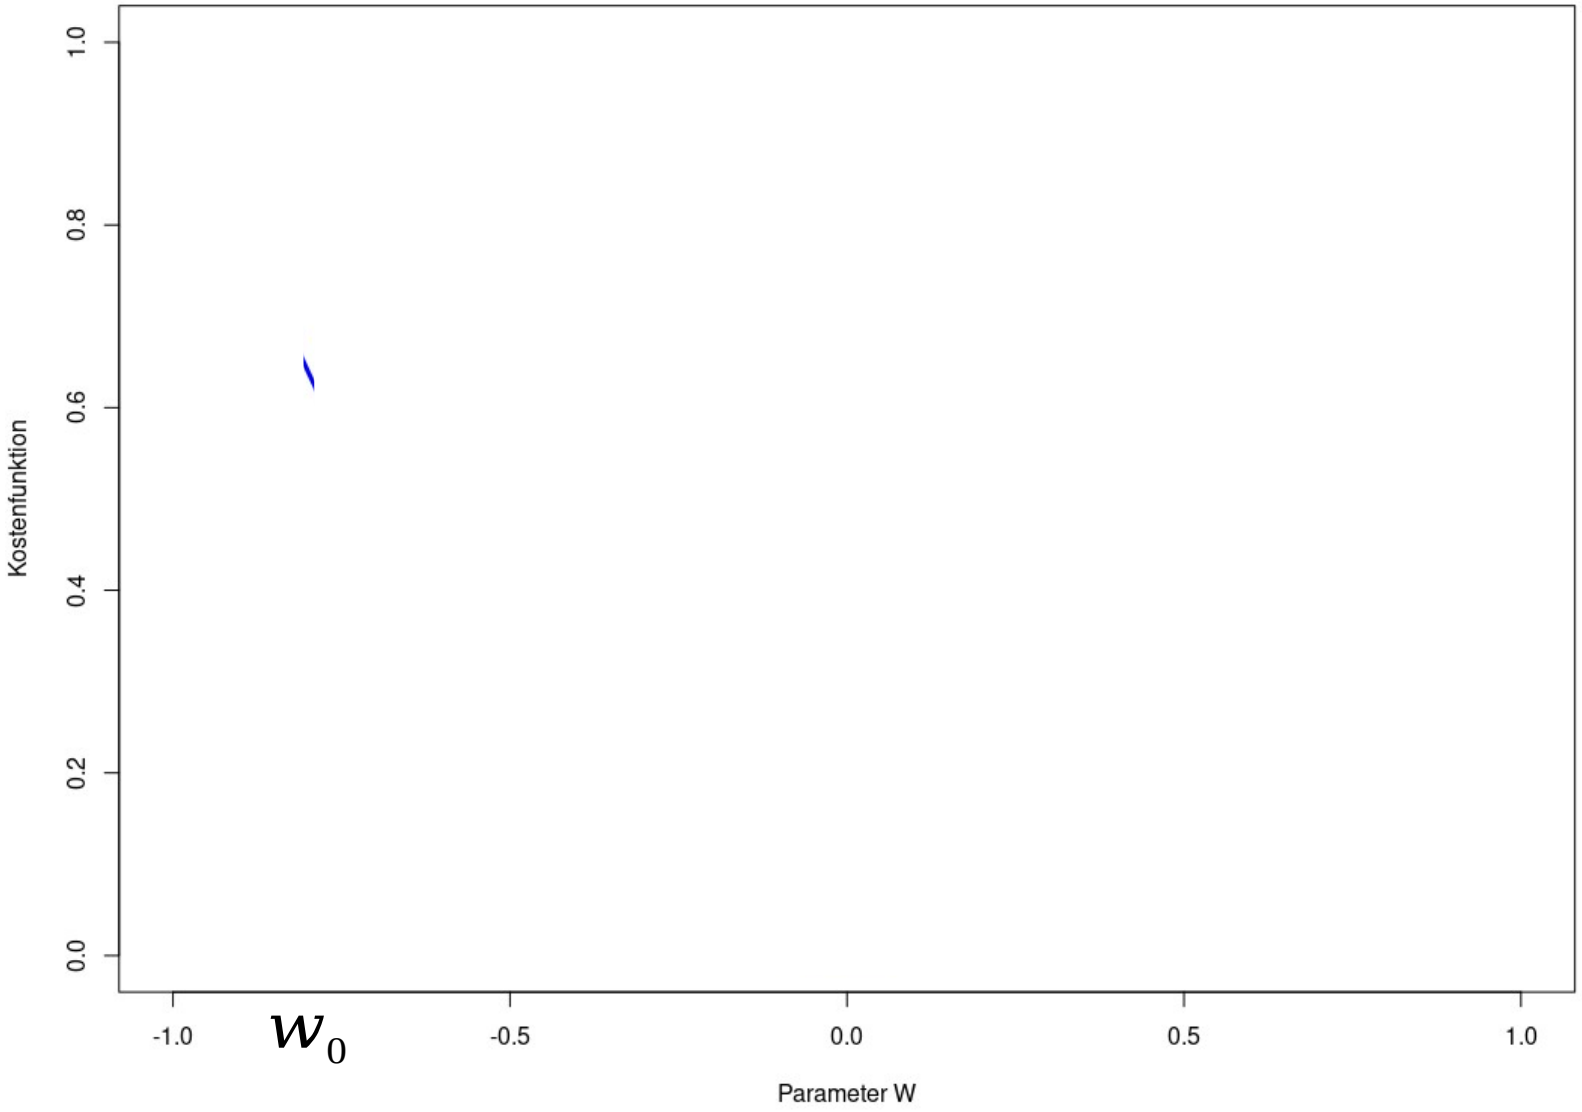

Beispiel () – Wo liegt ?

LINKS!

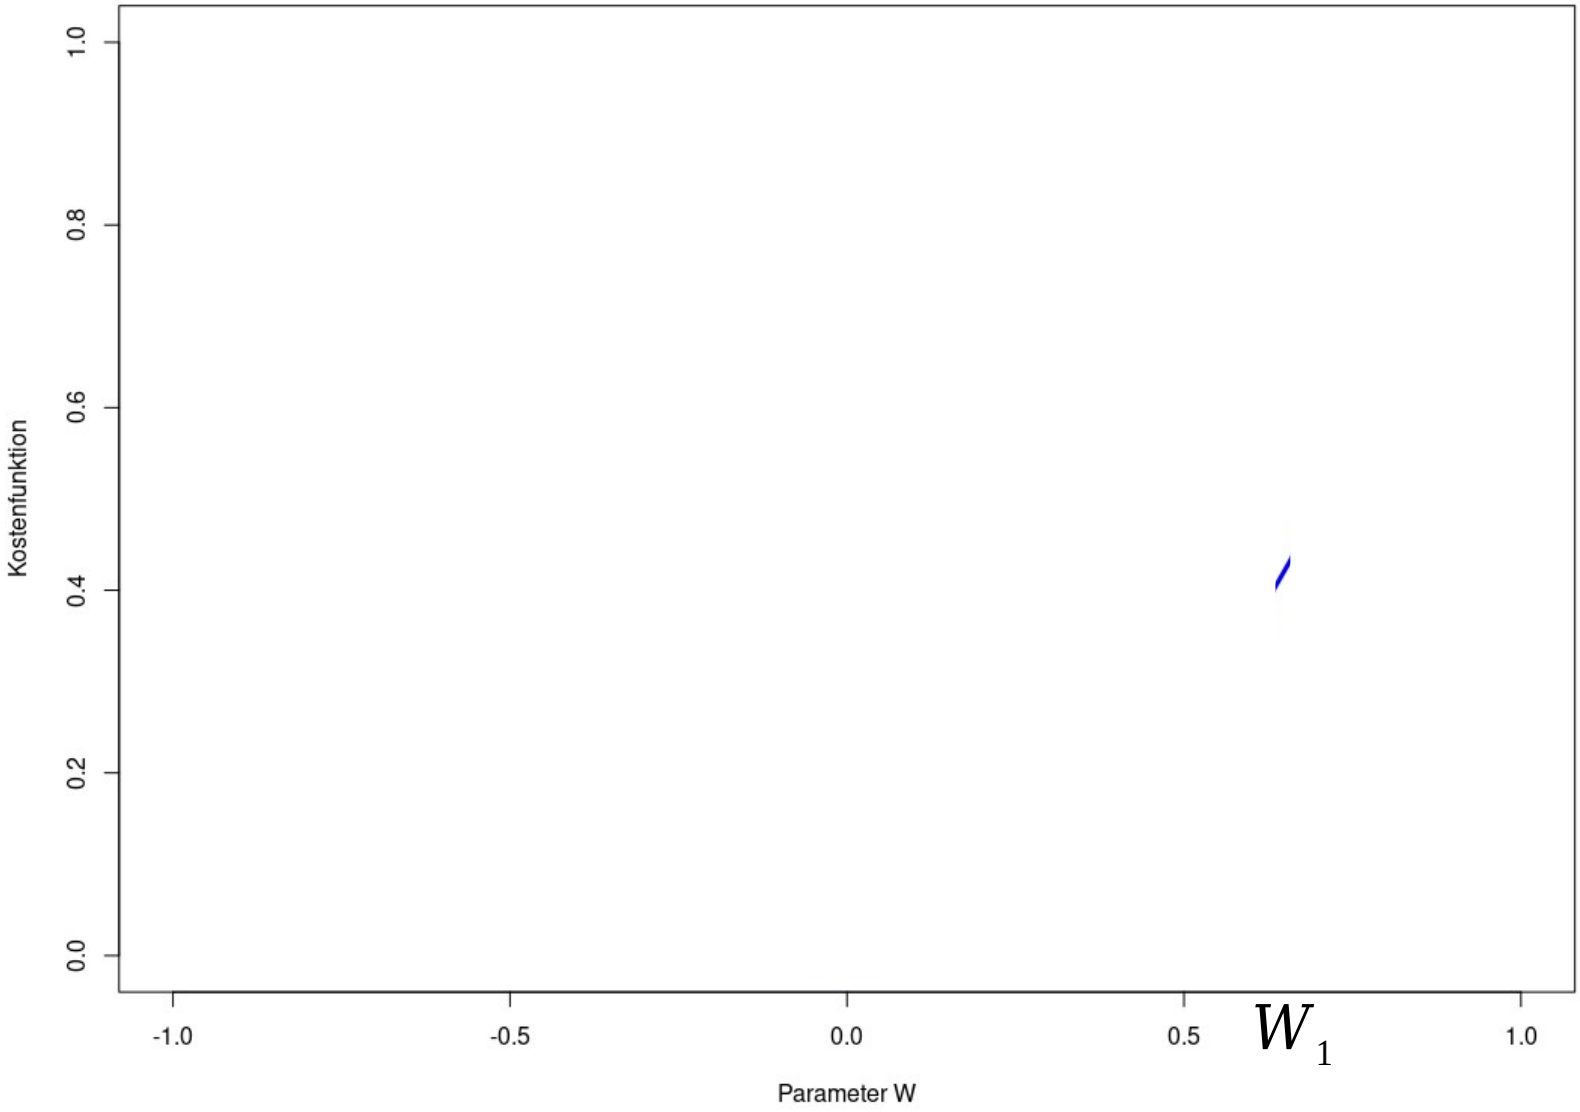

Beispiel () – Wo liegt ?

RECHTS!

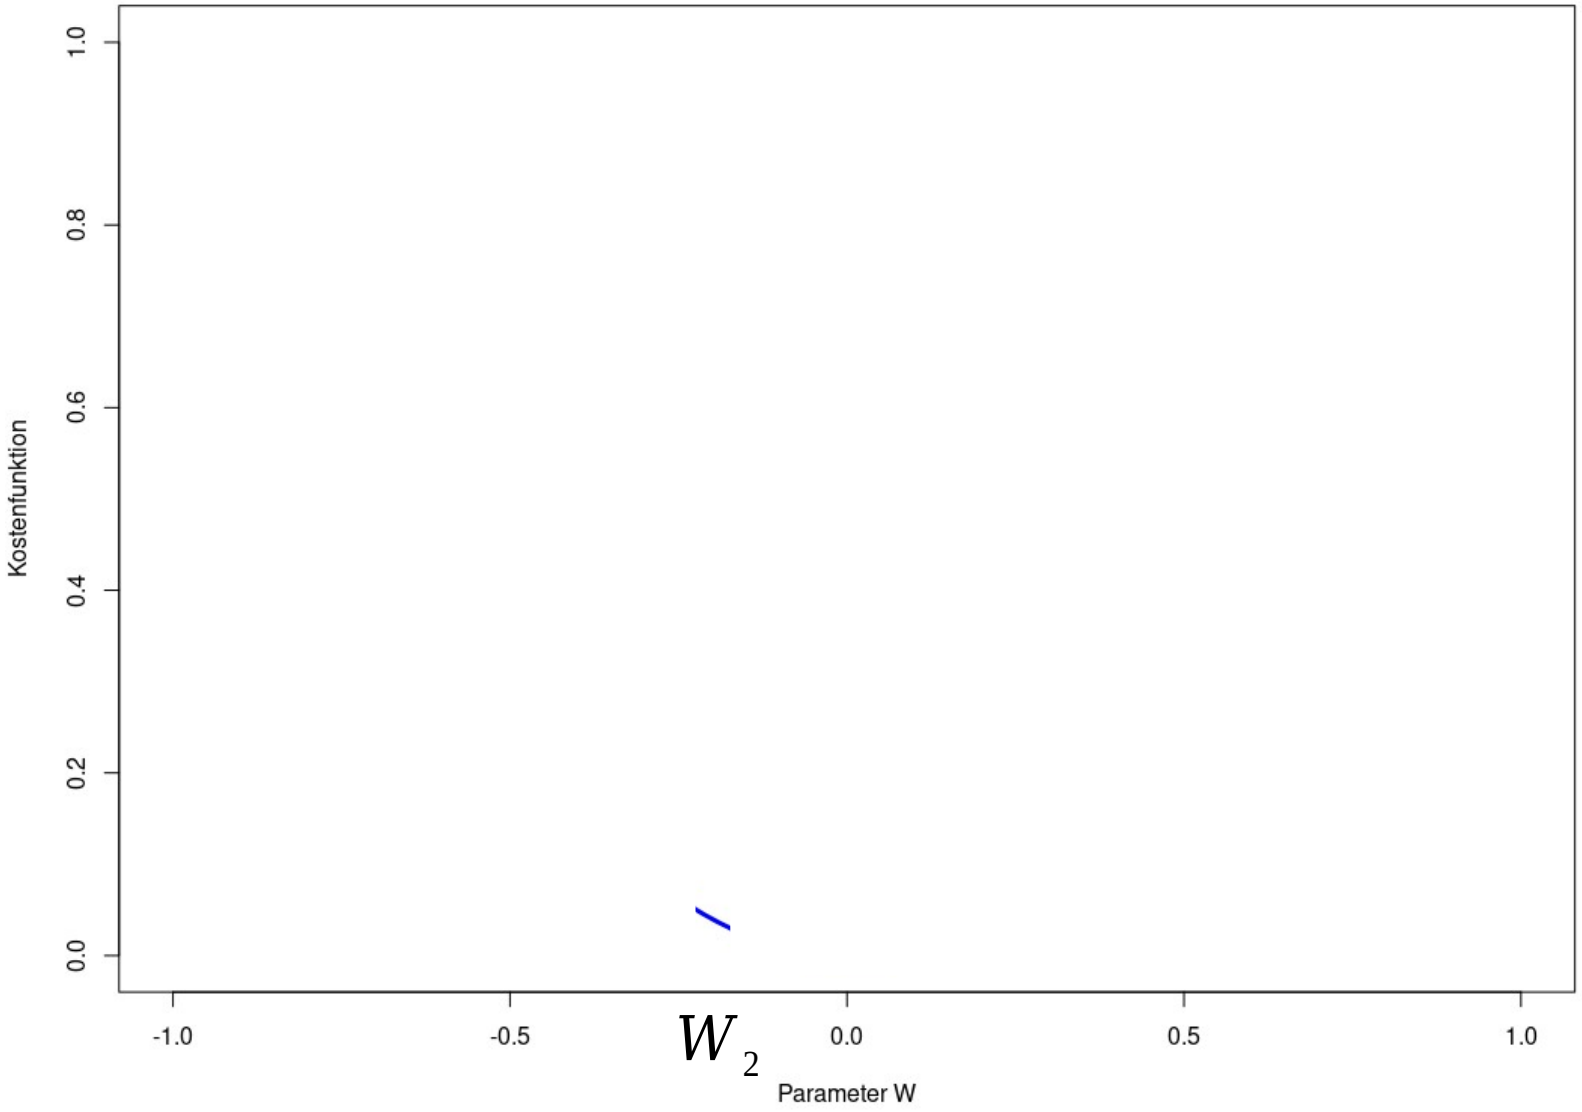

Beispiel () – Wo liegt ?

BLEIBEN!

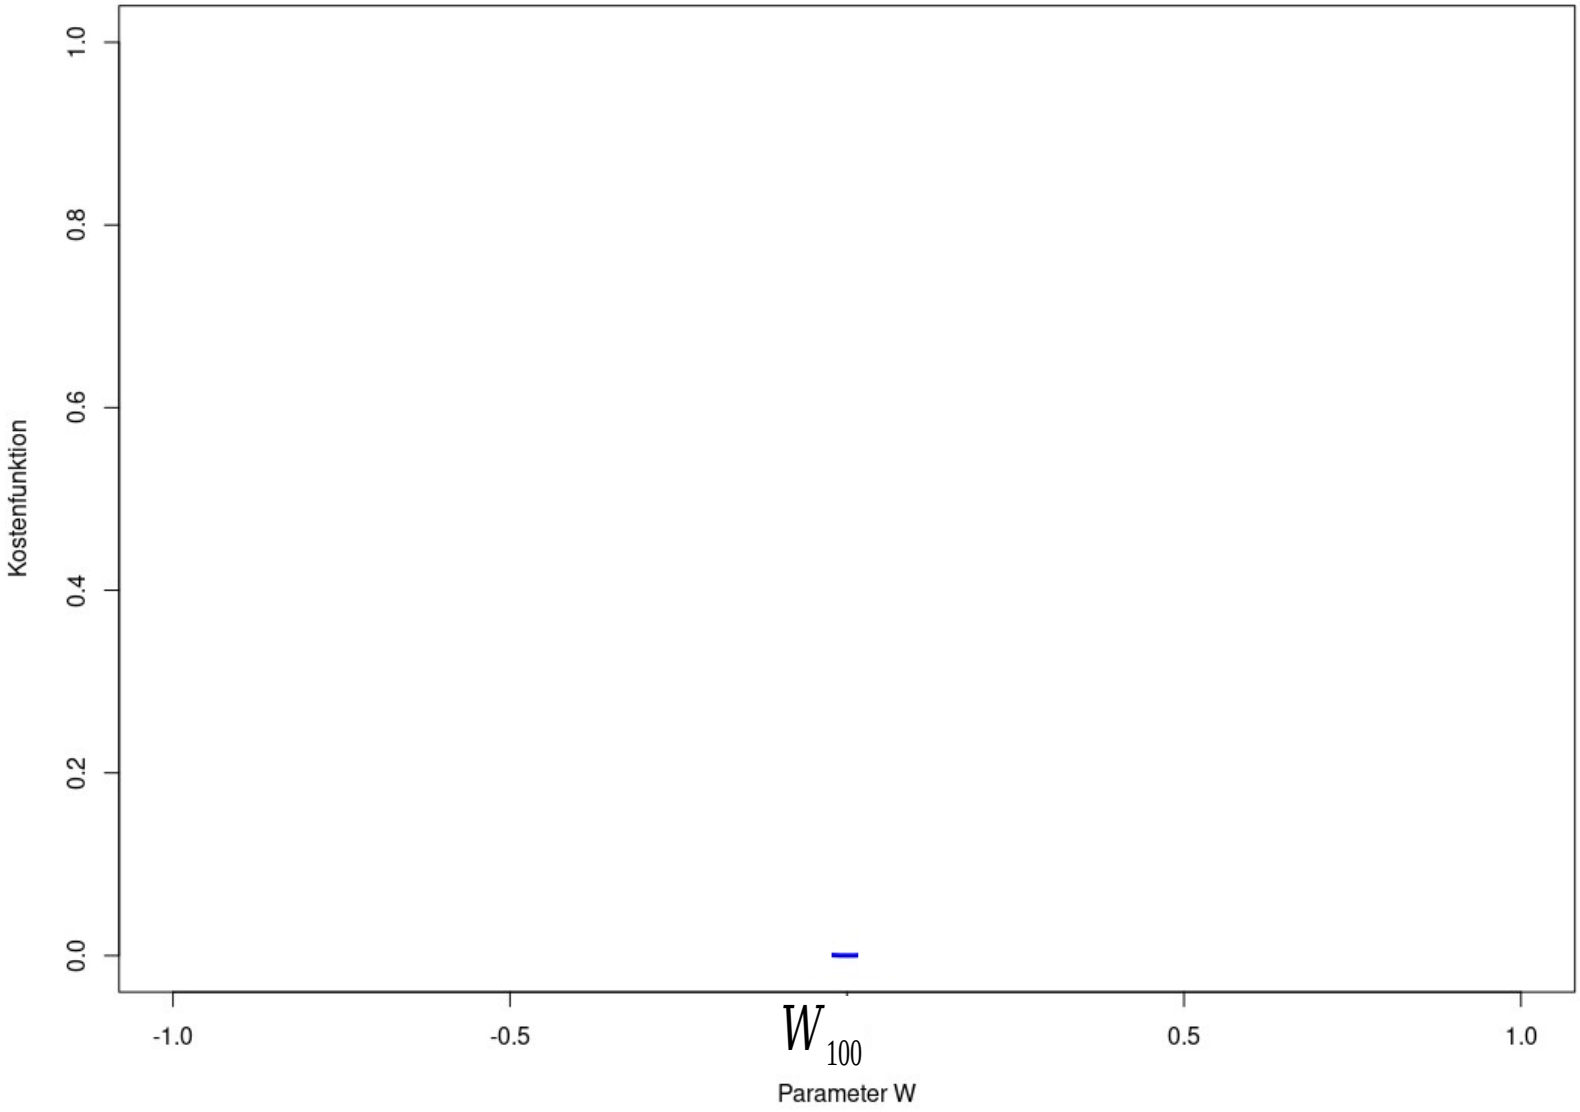

Beispiel ()

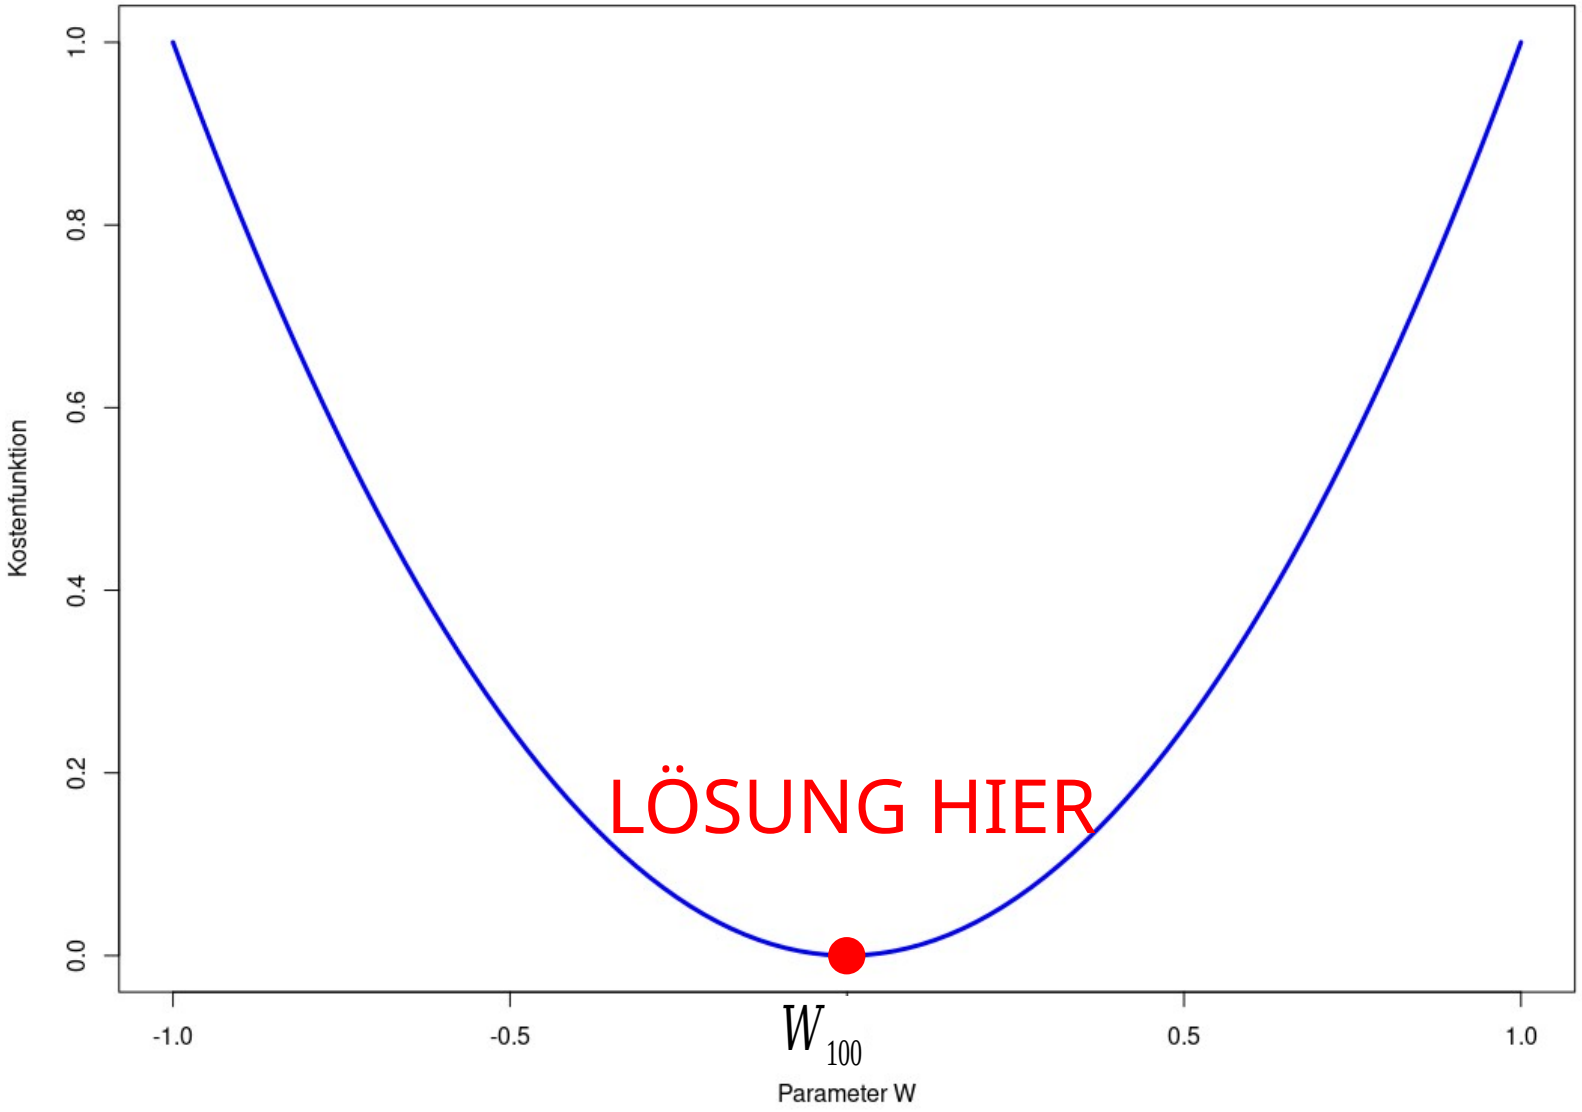
Kostenfunktion
1.0
0.8
0.6
0.4
0.2
0.0
LÖSUNG HIER
-1.0
-0.5
W_{100}
0.5
1.0
Parameter W

Wie minimiert man die Kostenfunktion?

Gradientenbasierter Abstieg:

1. Starte mit einer „beliebigen“ Belegung

2. Bestimme die Kostenfunktion
3. Bestimme die Richtung des stärksten Anstiegs der Kostenfunktion (**Gradient**) und gehe ein bisschen in die andere Richtung

4. Gehe zu Schritt 2

Beispiel: Kostenfunktion und W

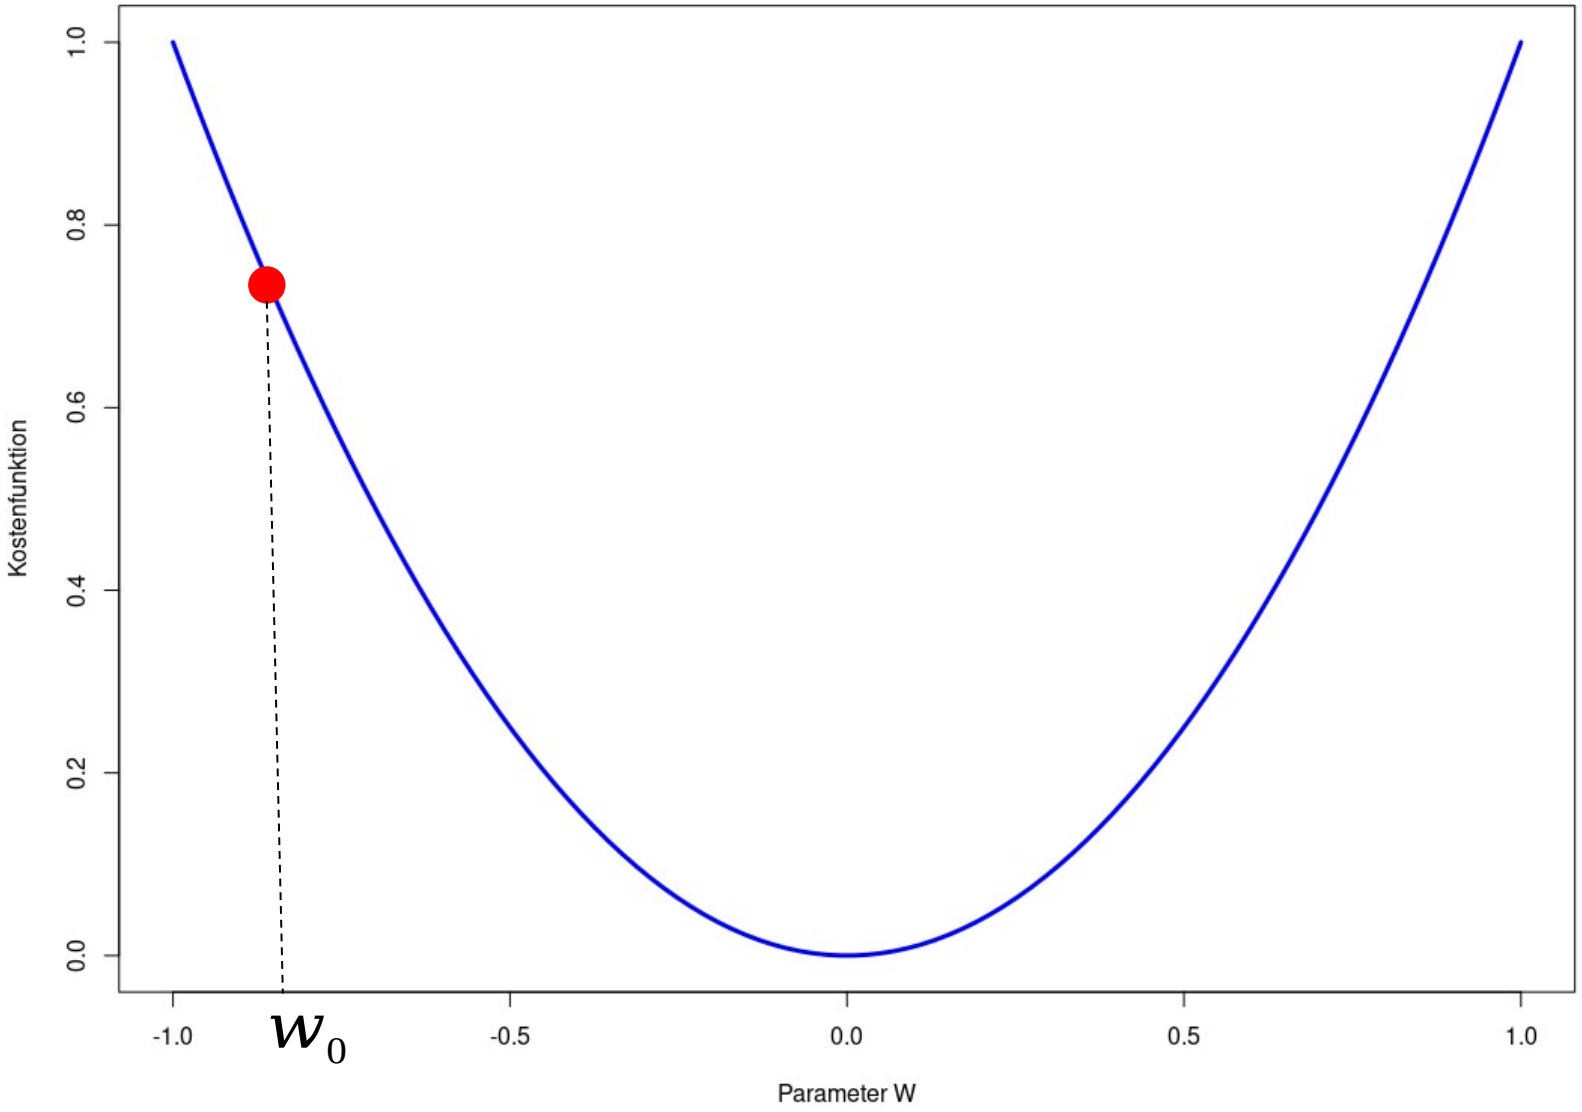

Beispiel: Gradient

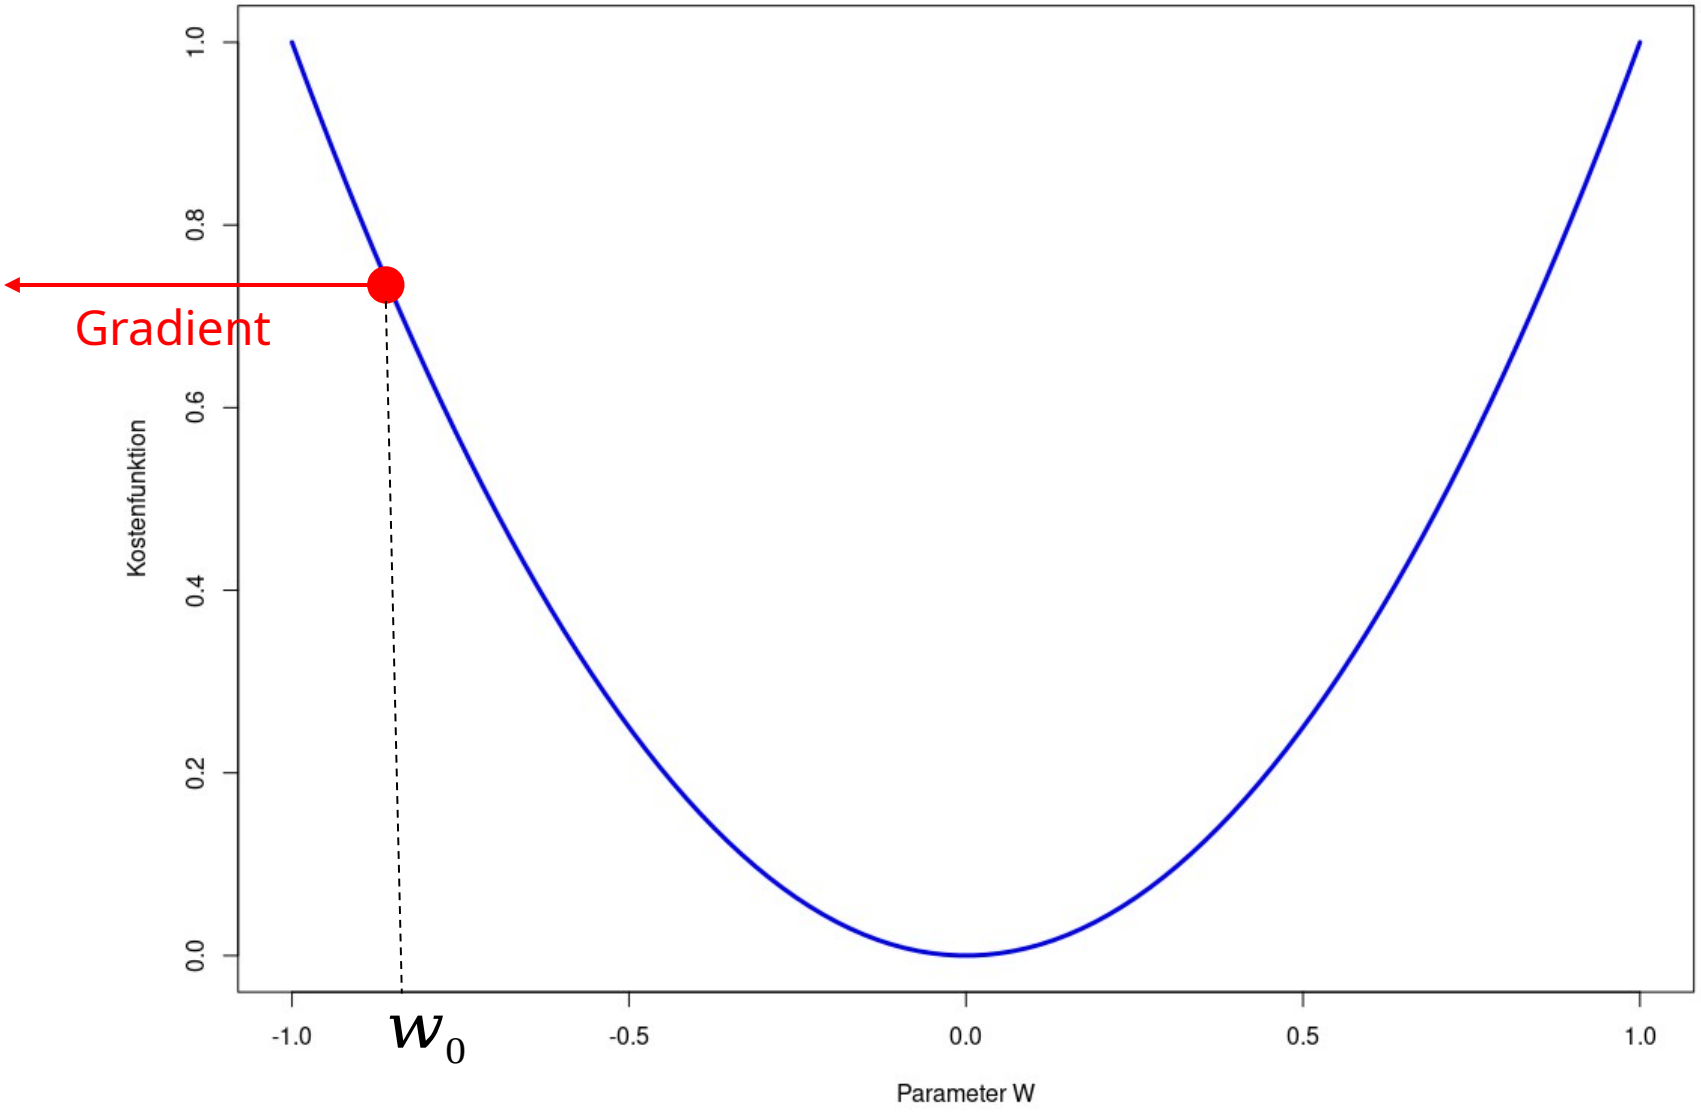

Beispiel: Schritt

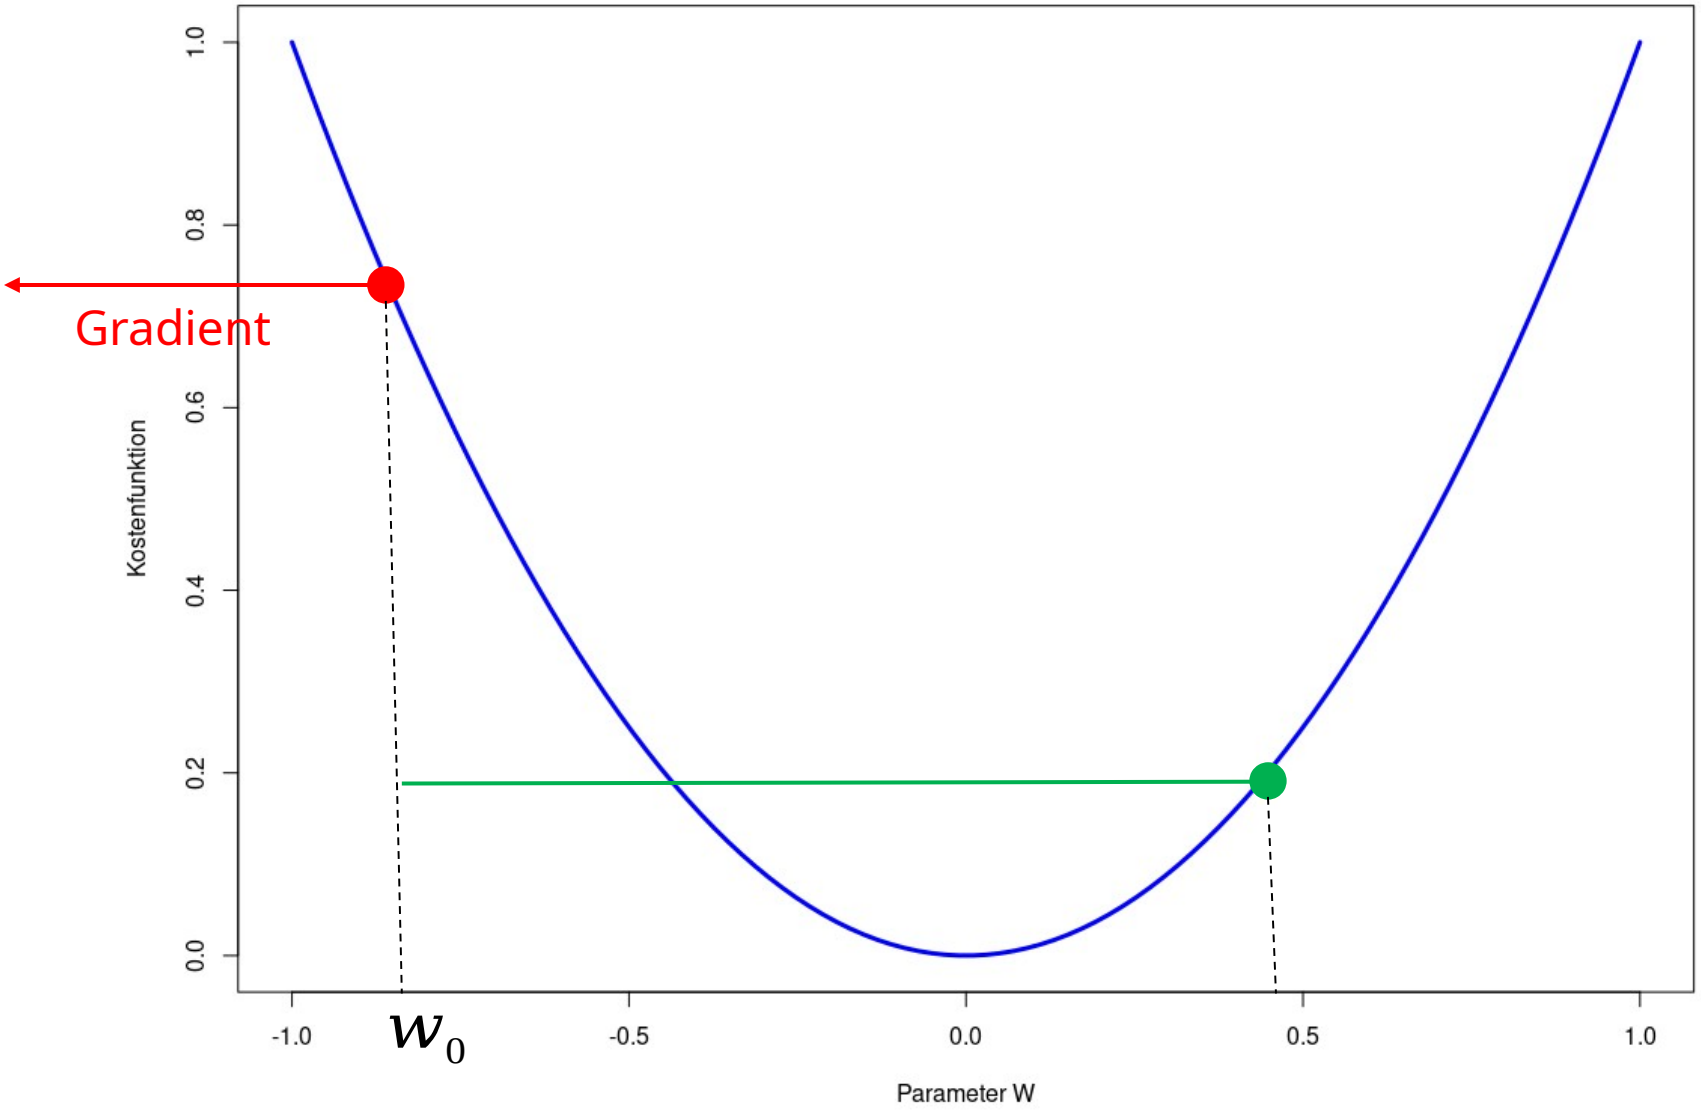

*Interpretation Gradient (ein Parameter)

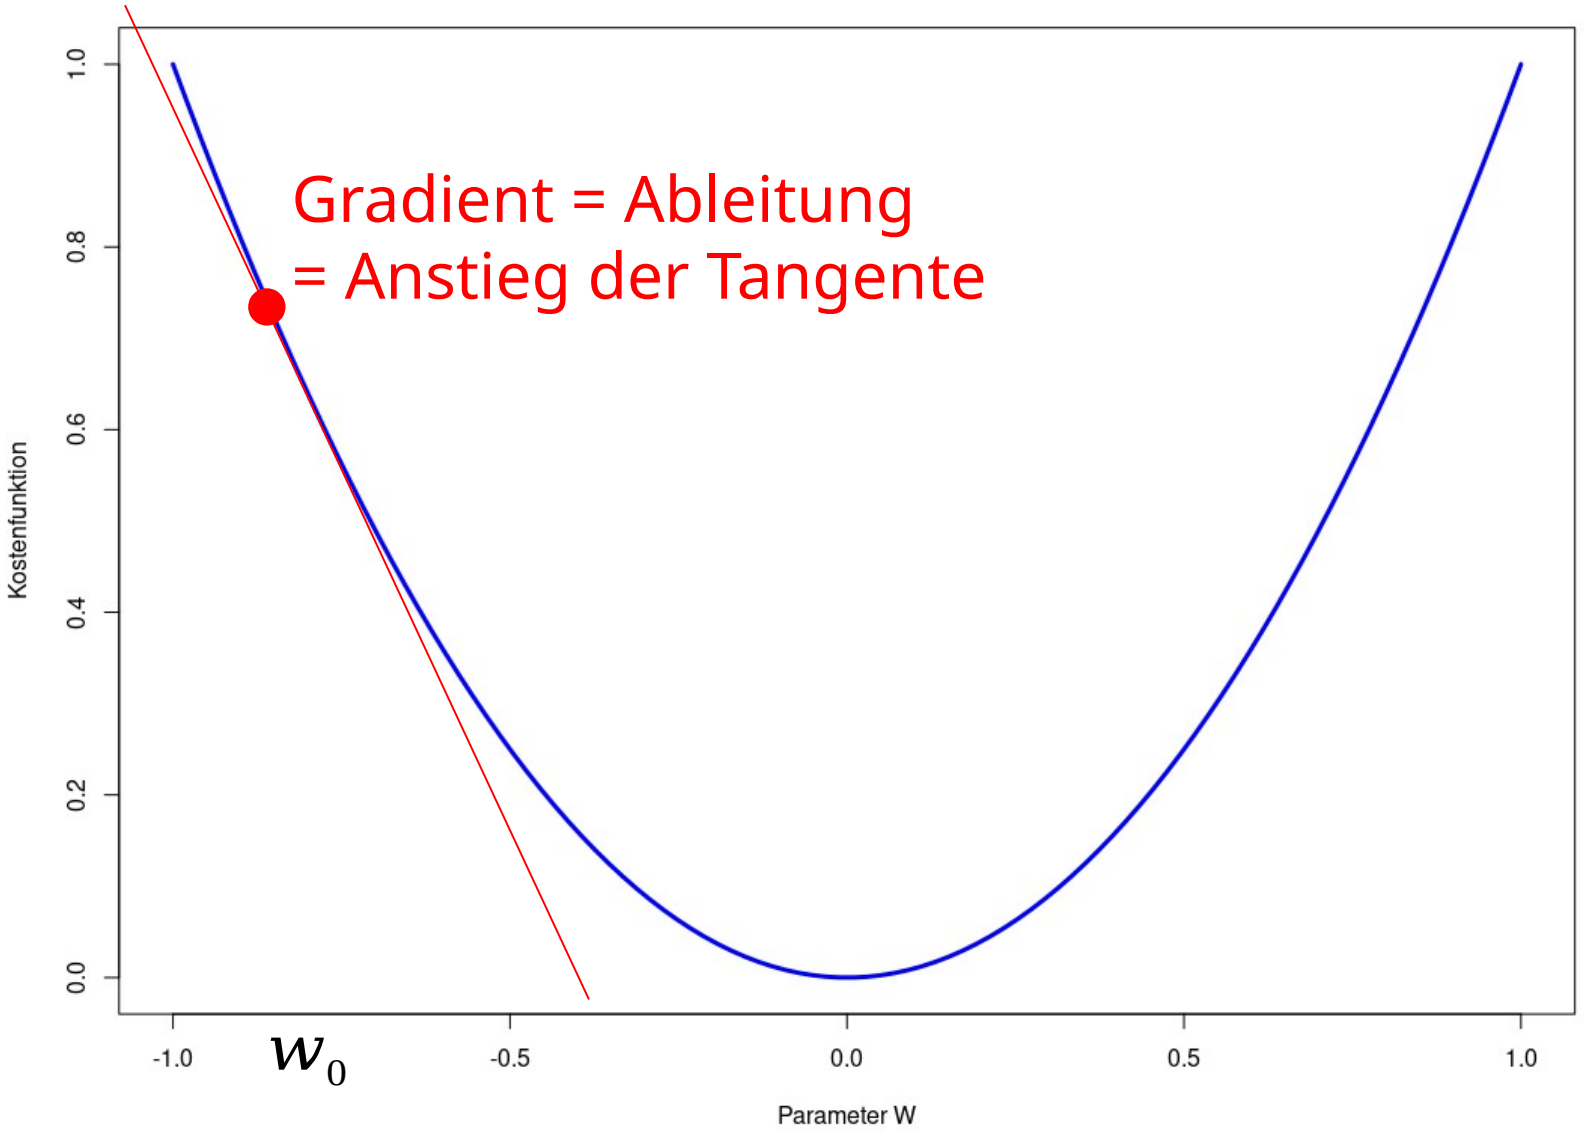

*Gradient (viele Parameter)

- 1 Parameter
  - Gradient = Ableitung
- Viele Parameter
  - Eine partielle Ableitung pro Parameter
  - Gradient = Vektor aller partiellen Ableitungen

Outline

1. Über euch und uns
2. Maschinelles Lernen
3. Vorwärts/Rückwärts
4. Workshop

Von der Theorie zur Praxis

- In der Praxis
  - Modelle haben viele Parameter (groß)
  - Modelle sind komplex (teuer)
  - Und wie bestimmt man den Gradienten?
- Schön wäre:
  1. Implementiere ein Programm, dass berechnet
  2. Gradientenberechnung passiert automatisch
  3. Effiziente Ausführung passiert automatisch
- Geht das?
  - **Ja, mit Informatik!**

Workshop: MLL

2. Vorwärts: Implementiere
   - Dazu entwickeln wir eine **domänenspezifische Sprache (DSL)** namens MLL
   - Programme in MLL erstellen **Rechengraphen**
   - Ausführung via Interpretation
3. Rückwärts: Gradientenberechnung
   - Mittels "Backpropagation"
   - Transformiert den Rechengraph (fügt weitere Operationen dazu)
4. Schneller: effiziente Ausführung
   - Wir kompilieren das MLL-Programm nach LLVM
   - Und dann in nativen Maschinencode
5. Finale: Maschinelles Lernen
   - Wir lernen ein Modell (logistische Regression) mit MLL

Ein Rechengraph in MLL

Rechengraph

- Blatt = Eingabe
- Innerer Knoten = Operation
- Ausgabe ganz unten
- Beispiel: logistische Regression, 1D, vorwärts

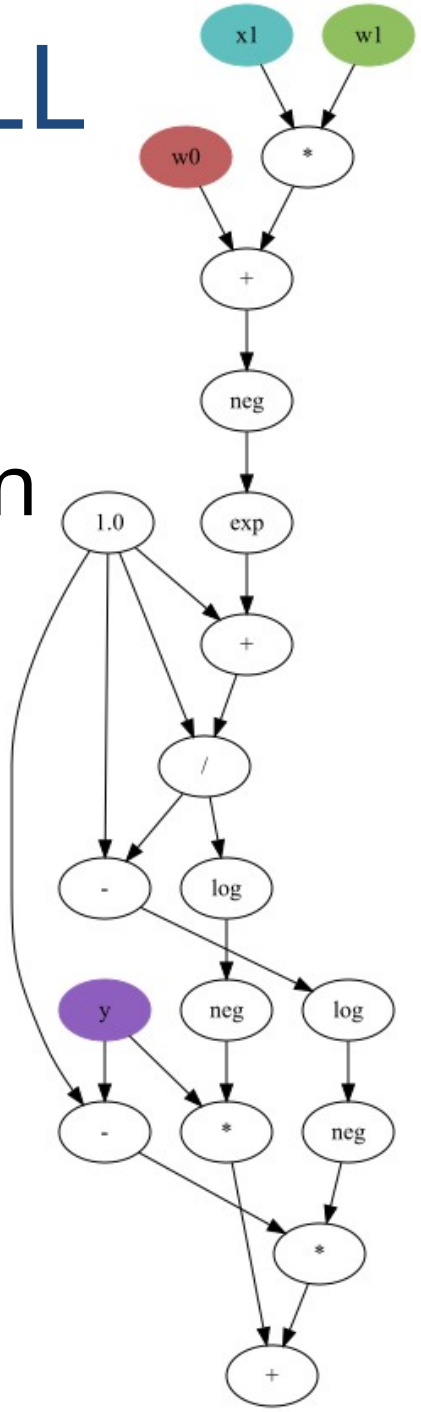

Systemunterstützung für ML

- Genauso funktionert das auch in realen ML-Systemen
  - Implementiere nur “vorwärts”
  - Automatische Gradientenberechnung, Optimierung, Kompilierung (z.B. auf die GPU) uvm.
- Beispiel: Rechengraph in Pytorch

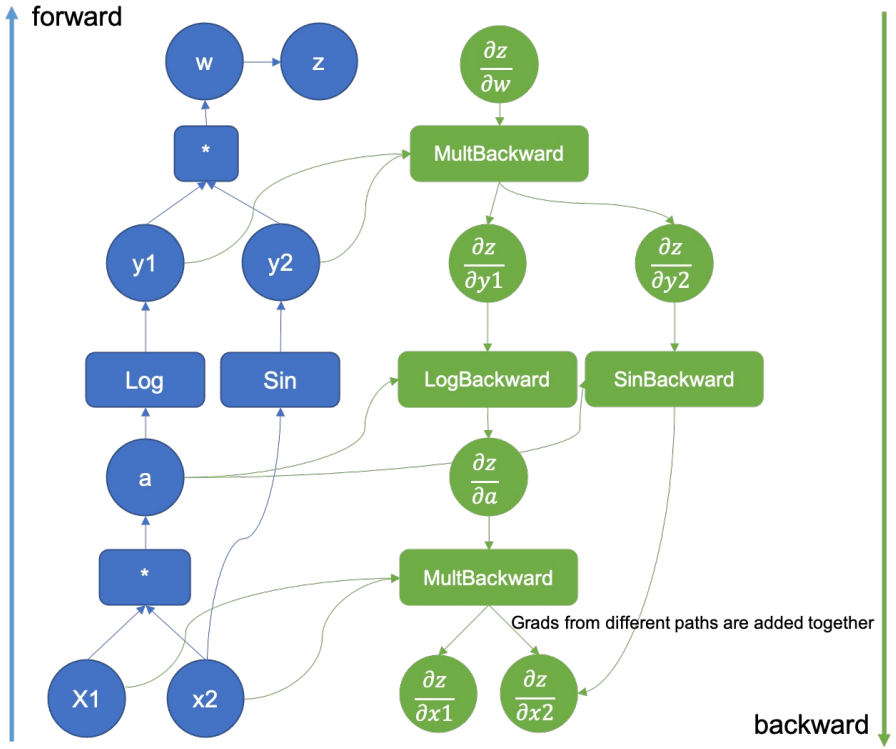

Ein Pytorch-Programm

```
# define model with one hidden layer
model = torch.nn.Sequential(
    torch.nn.Linear(dim_in, dim_hidden),
    torch.nn.ReLU(),
    torch.nn.Linear(dim_hidden, dim_out),
)

# define loss function (mean squared error)
loss_fn = torch.nn.MSELoss()

# pick optimizer (Adam)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-4)

# run for 500 epochs
for t in range(500):
    y_pred = model(X)           # forward: model output (X = examples)
    loss = loss_fn(y_pred, y)   # forward: loss (y = labels)
    model.zero_grad()           # clear old gradients
    loss.backward()             # backward
    optimizer.step()            # update parameters
```

Viel Spaß!